

LAPORAN TUGAS PROGRAM 3

ARTIFICIAL INTELLIGENCE

k-Nearest Neighbor



Oleh

Nama : I Putu Indra Aristya

NIM : 1301154219

Kelas : IF39-09

Mata Kuliah : Kecerdasan Buatan

Universitas Telkom

BANDUNG

2017

I. Deskripsi Masalah

Dalam tugas program-3 ini, kita diminta untuk menentukan sebuah kebenaran (hoax atau bukan) dari suatu berita dengan 4 atribut linguistik, yaitu berdasar Like, Provokasi, Komentar dan Emosi. Metode yang digunakan untuk menentukan kebenaran berita tersebut adalah *learning* menggunakan k-NN (*k-nearest neighbor*). Untuk menyelesaikan tugas program ini diberikan 2 buah tipe data, yaitu 4000 data *training* dan 1000 data *testing*. Data *training* digunakan untuk melatih/sebagai pembandingan dengan data *testing* atau data yang ingin dicari kebenarannya.

II. Landasan Teori dan Rancangan Program

Metode k-NN (*k-nearest neighbor*) adalah salah satu metode mengajarkan komputer (*learning*) yang biasa juga disebut dengan *lazy learning*. Disebut seperti itu karena metode ini membandingkan data yang ingin dicari dengan semua data latih yang sudah memiliki hasil dan diklasifikasikan dalam kelas. Dalam kasus ini, kelas yang ada hanya 2, yaitu kelas hoax (atribut bernilai 1) dan kelas tidak hoax (atribut bernilai 0).

Konsep dari k-NN ini adalah sesuai dengan arti dari k-NN jika diterjemahkan ke dalam bahasa Indonesia, yaitu tetangga yang terdekat. Tetangga terdekat tersebut di dapat dari menghitung jarak dari data yang ingin dicari dengan semua data latih. Pasangan data dengan jarak terkecil memiliki kemungkinan kemiripan lebih besar. Penghitungan jarak dapat digunakan dengan perhitungan *Manhattan* atau *Eclidean*. Pada tugas ini, saya menggunakan perhitungan *Manhattan* dengan rumus sebagai berikut.

$$d_i(x_i, y_i) = \sum_i |x_i - y_i|$$

dengan x dan y adalah nilai dari masing-masing atribut dari data latih dan data *test*. Karena atribut pada tugas program ini lebih dari 1, maka x dan y mewakili setiap data latih dan data *test*-nya kemudian dijumlahkan dengan atribut lain.

Variabel *k* pada k-NN mewakili suatu nilai integer yang berguna untuk mengambil *k* banyak data yang terkecil untuk dilakukan klasifikasi.

Dari landasan teori tersebut, dapat diringkas algoritma k-NN ini menjadi:

1. Hitung jarak dari data *test* dengan semua data latih yang ada

2. Pilih k nilai terkecil dari jarak yang sudah dihitung tadi
3. Lihat label kebenaran (1/0) dari data latih dengan indeks dari k nilai terkecil tersebut
4. Jika label 1 lebih banyak maka data tersebut hoax dan jika label 0 lebih banyak maka data tersebut tidak hoax
5. Lakukan langkah 1 sampai 4 tadi untuk semua data *test*

Pada tugas program ini, saya menggunakan perhitungan jarak Manhattan karena terlihat lebih sederhana dan penentuan nilai k adalah dengan random. Jadi saya mencoba setiap kemungkinan nilai k yang bisa digunakan kemudian mencoba menjalankan program. Dari hasil dengan membagi data latih menjadi data latih (3500 data pertama dari data latih) dan data validasi (500 data setelahnya dari data latih) ditentukan label dari data validasi dengan $k = 59$ didapat akurasi 70.8%.

III. Code Program

Dalam tugas program-1 ini, saya menggunakan bahasa pemrograman *Python* dengan IDE *PyCharm CE*. Berikut adalah *code* program yang sudah saya buat.

```
from numpy import genfromtxt
import numpy as np

dataTrain = genfromtxt('DATA_TRAIN.csv',delimiter=',')
dataTest = genfromtxt('DATA_TEST.csv',delimiter=',')
dataTesting = genfromtxt('DATA_TESTING.csv',delimiter=',')

#Like 0
#Provokasi 1
#Komentar 2
#Emosi 3
#Hoax 4
#k=59

hasilManhattan = 0
manhattanTemp = [] * 10000
hasilnya = [0] * 4000 #untuk testing
#hasilnya = [0] * 3500 #untuk validasi
trainRow = 0
validRow = 0
i = 0
kNN = 0
kesimpulan = 0
arraykNN = [0] * 59
countHoax = 0
countTdk = 0
```

```

def manhattan(x,y):
    hasil = x - y
    if (hasil < 0):
        hasil = -1*hasil
    return hasil

#-----CODE UNTUK VALIDASI-----#
# for validRow in range(0,500):
#     for trainRow in range(0,3499):
#         like = manhattan((dataTrain[trainRow, 0]), (dataTest[validRow, 0]))
#         provo = manhattan((dataTrain[trainRow,1]),(dataTest[validRow,1]))
#         komen = manhattan((dataTrain[trainRow,2]),(dataTest[validRow,2]))
#         emosi = manhattan((dataTrain[trainRow,3]),(dataTest[validRow,3]))
#         #print(i)
#         hasilnya[i] = like + provo + komen + emosi
#         i=i+1
#     if (i == 3499):
#         arrayManhattan = np.array(hasilnya)
#         indexSorted = np.argsort(arrayManhattan)
#         list.sort(hasilnya)
#         # print(arrayManhattan)
#         # print(indexSorted)
#
#         while (kNN < 58):
#             arraykNN[kNN] = dataTrain[indexSorted[kNN],4]
#             #print(arraykNN[kNN])
#             if (arraykNN[kNN] == 0.0):
#                 countTdk = countTdk + 1
#             elif (arraykNN[kNN] == 1.0):
#                 countHoax = countHoax + 1
#             kNN = kNN + 1
#             if (countTdk > countHoax):
#                 ht = 0
#             elif (countTdk < countHoax):
#                 ht = 1
#             #print("KNN: ",kNN)
#             #print(countTdk, " ",countHoax," ",ht)
#             print(ht)
#
#             kNN = 0
#             i = 0
#             countHoax = 0
#             countTdk = 0
#
#         #print(indexSorted)
#         #print(validRow)
#
#-----CODE UNTUK TESTING-----#
for testRow in range(0,1000):
    for trainRow in range(0,3999):
        like = manhattan((dataTrain[trainRow, 0]), (dataTesting[testRow, 0]))
        provo = manhattan((dataTrain[trainRow,1]),(dataTesting[testRow,1]))
        komen = manhattan((dataTrain[trainRow,2]),(dataTesting[testRow,2]))
        emosi = manhattan((dataTrain[trainRow,3]),(dataTesting[testRow,3]))
        hasilnya[i] = like + provo + komen + emosi #perhitungan distance
        ditampung pada array hasilnya.
        i=i+1
    if (i == 3999):
        arrayManhattan = np.array(hasilnya)
        indexSorted = np.argsort(arrayManhattan) #melakukan sorting

```


